Avaliação Dinâmica com IA — Embasamento e Conceito

Oct 31, 2026 · @Luís Fernando Laguardia

Reposicionamento

O projeto deixa de ser um corretor automático de provas e passa a ser um sistema de **avaliação dinâmica**: ele corrige a prova escrita e, quando a resposta não basta como evidência, conversa com o aluno para medir o que ele realmente entende.

Tese em uma frase: a nota diz onde o aluno está; a avaliação dinâmica diz até onde ele chega com ajuda, e isso é o que o professor precisa para agir.

	Antes: corretor automático	Agora: avaliação dinâmica
Pergunta que responde	Quanto o aluno tirou?	O que o aluno entende e o que falta para ele chegar lá?
Evidência usada	Só o texto escrito	Texto escrito + respostas a follow-ups
Saída	1 nota + explicação	3 notas: real, mediada e potencial de aprendizagem
Valor para o professor	Economiza tempo	Diagnóstico acionável por aluno e por turma
Valor para o aluno	Sabe por que errou	Aprende durante a própria avaliação
Resposta à IA generativa	Assume que o texto é do aluno	Verifica autoria pelo entendimento demonstrado

Pitch de 30 segundos: desde a IA generativa, a resposta escrita deixou de ser prova de entendimento. Universidades estão voltando ao exame oral, mas ele não escala. Nosso sistema corrige a prova escrita e, só quando a resposta é ambígua, rasa ou suspeita, faz de 1 a 3 perguntas de follow-up com ajuda graduada. O professor recebe não só a nota, mas quanto de ajuda cada aluno precisou, um diagnóstico que nenhum corretor automático entrega hoje.

Nome provisório para o conceito: *Corretor que pergunta de volta* (ajustem para a marca do projeto).

Embasamento científico

A ideia se apoia em quatro linhas de pesquisa independentes, de três décadas de literatura até estudos de 2025–2026 com IA.

1. Pedir justificativa revela o que a resposta esconde

- **Autor:** David Treagust (Curtin University), testes diagnósticos de dois níveis, 1988.
- **Ideia:** o primeiro nível pede a resposta; o segundo, o porquê. A justificativa expõe concepções alternativas (equívocos) que a resposta sozinha não mostra.
- **Evidência:** Tamir (1989) mostrou que pedir justificativas é uma forma sensível e eficaz de avaliar aprendizagem significativa. Tsui & Treagust (2010), em genética, encontraram alunos que escolheram a resposta certa sem escolher uma explicação adequada.
- **Uso no projeto:** acertar não prova entendimento. O follow-up de justificativa é o "segundo nível" aplicado a questões abertas.

2. Avaliação Dinâmica: medir a resposta à ajuda

- **Autores:** L. S. Vygotsky (Zona de Desenvolvimento Proximal); Reuven Feuerstein; Matthew Poehner e James Lantolf (Penn State).
- **Ideia:** avaliação e ensino acontecem juntos, por meio de mediação. Quanto e que tipo de ajuda o aluno precisa revela seu nível de desenvolvimento.
- **Mediação graduada:** começa implícita e fica mais explícita conforme a necessidade do aluno (lembretes, perguntas condutoras, pistas, modelos).
- **Três notas:** a Avaliação Dinâmica computadorizada (Poehner & Lantolf, 2013) gera nota real (sem ajuda), nota mediada (com ajuda) e score de potencial de aprendizagem (o ganho entre as duas).
- **Uso no projeto:** é o núcleo teórico. É o que transforma "IA que faz perguntas" em instrumento de avaliação com construto definido.

3. Oral interativo como resposta à IA generativa

- **Autora:** Popi Sotiriadou (Griffith University), modelo Interactive Oral, com Danielle Logan-Fleming.
- **Evidência de adoção:** usado desde 2015 e implementado em mais de 30 universidades na Australásia, Europa e Sudeste Asiático; há comunidades de prática também na Irlanda (DCU), Singapura e EUA.
- **Argumento:** por ser personalizado e interativo, o formato dificulta que o aluno dependa de conteúdo terceirizado ou gerado por IA.

- **Desempenho:** Huxham, Campbell & Westwood (2012, Edinburgh Napier) encontraram desempenho significativamente maior no oral que no escrito, e alunos o viram como mais útil e autêntico.
- **Limite:** professores raramente aplicam orais por falta de tempo. É exatamente o gargalo que a IA remove.

4. Follow-ups conduzidos por IA já funcionam

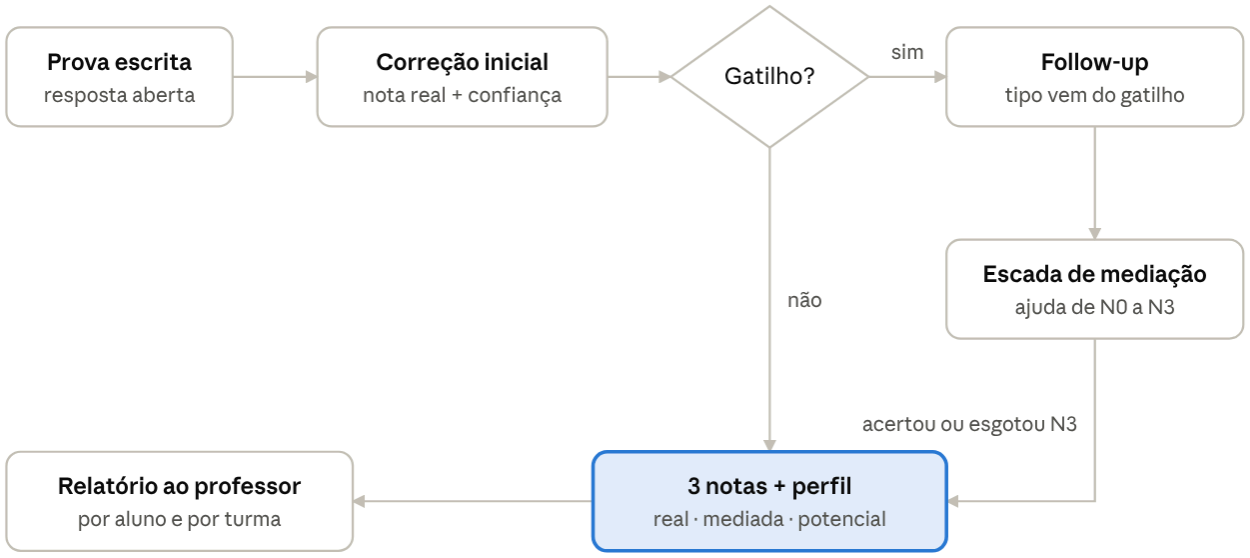
- **Socratic Mind (Georgia Tech + UC San Diego):** estudo com 173 alunos de CS 1301 trouxe a primeira evidência empírica de que o questionamento socrático mediado por IA melhora engajamento e aprendizagem. Piloto com 2.000 alunos em 2025.
- **NYU (Prof. Panos Ipeirotis):** 36 exames orais em nove dias por cerca de US$ 15 em custo de IA.
- **Cambridge (TESOL Quarterly, 2025):** um sistema de diálogo com LLM conseguiu conduzir uma entrevista estruturada fazendo follow-ups adequados, com percepção positiva dos candidatos.
- **Qualidade de follow-ups (Scientific Reports, 2026):** psicolinguistas avaliaram 1.658 follow-ups gerados por LLM em quatro critérios: benevolência, necessidade, consciência de contexto e abertura.

Como isso sustenta o argumento

Os pilares 1 e 2 dizem **por que** perguntar de volta mede melhor; o 3 diz **por que agora** (IA generativa); o 4 diz que **é viável** com IA. O que nenhuma dessas linhas faz é acoplar a avaliação dinâmica a uma prova escrita já corrigida, que é a lacuna que o projeto ocupa.

Conceito do gerador de follow-ups

O gerador só entra em ação quando a resposta escrita não basta como evidência. Aí faz de 1 a 3 perguntas com ajuda graduada e registra quanto de ajuda o aluno precisou para chegar lá.



fluxo do gerador de follow-ups · 1 decisão, 4 etapas

Sem gatilho, a nota real vira a nota final e o aluno nem percebe o sistema. Com gatilho, a conversa alimenta as três notas.

Quando ativa: 5 gatilhos

Gatilho	Sinal detectado	Por que perguntar	Base
G1 Acerto sem justificativa	Resposta certa, raciocínio ausente ou genérico	Acerto pode ser chute ou memorização	Treagust (dois níveis)
G2 Resposta parcial	Cobre só parte dos critérios da rubrica	O aluno pode saber mais do que escreveu	Interactive Oral
G3 Ambiguidade	Confiança do corretor abaixo do limiar	A nota depende de interpretação	Calibração do corretor
G4 Equívoco conhecido	Erro bate com um equívoco catalogado	O aluno pode estar a uma pista do acerto	Avaliação Dinâmica
G5 Autoria incerta	Estilo destoa das outras respostas do aluno	Verificar entendimento, nunca acusar	Sotiriadou

Regra de custo: no máximo 3 questões com follow-up por aluno e 3 turnos por questão, para limitar tempo e ansiedade.

Como gera a pergunta

O **tipo** da pergunta é fixo por gatilho (garante padronização entre alunos); o **conteúdo** é adaptado à resposta (garante personalização). Exemplo com a questão "Qual a complexidade da busca binária e por quê?":

Gatilho	Tipo de pergunta	Exemplo
G1	Justificativa	"Você respondeu O(log n). O que acontece com o tamanho do problema a cada passo?"
G2	Elaboração	"Você disse que divide o vetor. Que condição o vetor precisa cumprir para isso funcionar?"
G3	Esclarecimento	"Quando você diz 'metade', fala do vetor inteiro ou do intervalo de busca?"
G4	Confronto com equívoco	"Um colega disse que a busca binária funciona em qualquer vetor. Você concorda?"
G5	Transferência	"E se o vetor estivesse em ordem decrescente, o que mudaria no algoritmo?"

Insumos do prompt: enunciado, rubrica, resposta do aluno, gatilho acionado e o banco de equívocos da disciplina, que a própria turma alimenta a cada prova.

Checklist de qualidade (critérios do estudo da Scientific Reports, 2026, mais dois nossos):

- Benevolente: tom neutro, sem sugerir que o aluno errou ou colou
- Necessária: só pergunta o que muda a nota ou o diagnóstico
- Contextualizada: cita a resposta do próprio aluno
- Aberta: não pode ser respondida com sim ou não
- Não entrega a resposta nos níveis N0 e N1
- Uma ideia por pergunta

Escada de mediação

Baseada na mediação graduada da Avaliação Dinâmica: começa implícita e só fica explícita se o aluno precisar.

1. **N0, sem ajuda:** a pergunta do tipo escolhido.
2. **N1, pista implícita:** direciona a atenção. "Releia o que você escreveu sobre o vetor."
3. **N2, pista conceitual:** nomeia o conceito. "Pense no que a ordenação permite descartar."

4. **N3, pista explícita:** oferece um modelo. "A cada passo descartamos metade dos elementos. Quantos passos até sobrar um?"

A escada para quando o aluno acerta ou esgota o N3. Se ele acertou com ajuda, uma pergunta de transferência sem ajuda confirma que internalizou, como nos itens de transferência da Avaliação Dinâmica computadorizada.

As três notas

- **Nota real:** a correção da prova escrita. Um esclarecimento (G3) pode ajustá-la, porque esclarecer não é ajudar.
- **Nota mediada:** pontos recuperados na conversa, ponderados pelo nível de ajuda. Proposta inicial, configurável pelo professor: N0 vale 100% do ponto, N1 75%, N2 50%, N3 25%, sem acerto 0%.
- **Potencial de aprendizagem:** o ganho da nota mediada sobre a real, dividido pelo que faltava para a nota máxima.

Os pesos são decisão de design, não valores da literatura; devem ser calibrados com professores no piloto.

Perfis que o professor recebe

Nota real	Ganho com ajuda	Perfil	Ação sugerida
Alta	Não se aplica	Domina	Avançar
Baixa	Alto, com pouca ajuda (N0–N1)	Quase lá	Revisão curta
Baixa	Só com ajuda explícita (N2–N3)	Em construção	Reensino guiado
Baixa	Nenhum	Não alcançou	Reensino do conceito
Alta na escrita	Baixo no follow-up	Verificar entendimento	Conversa com o professor

O professor sempre tem a palavra final e vê a transcrição de cada conversa.

Diferencial e riscos

O diferencial não é "IA que faz perguntas", que já existe, e sim acoplar a avaliação dinâmica à prova escrita: a conversa só acontece onde a escrita falhou como evidência, e a saída mede a resposta à ajuda.

Abordagem	Ponto de partida	O que entrega	Limite
Corretor automático (o projeto antes)	Prova escrita	Nota + explicação	Assume que o texto prova entendimento
Interactive Oral (Sotiriadou)	Conversa ao vivo com o professor	Nota por rubrica, alta autenticidade	Não escala: exige tempo do professor
Socratic Mind (Georgia Tech)	Avaliação oral com IA, separada da prova	Questionamento socrático em escala	É outra avaliação, não complementa a prova que já existe
Este projeto	Prova escrita já corrigida	3 notas + perfil de cada aluno	Pesos e gatilhos ainda precisam de validação

Riscos e mitigação

Risco	Mitigação
Ansiedade do aluno: em Huxham et al. (2012) alunos ficaram mais nervosos no oral, mas Phan (UC San Diego, ASEE 2023) mediu estresse percebido menor no oral que no escrito	Follow-up escrito e curto, só quando acionado, tom benevolente, no máximo 3 questões
Adaptatividade vs. padronização: perguntas diferentes por aluno podem parecer injustas	Tipo de pergunta fixo por gatilho, conteúdo adaptado, transcrição salva
Falso positivo de autoria (G5)	Nunca rotular como cola; o perfil é "verificar entendimento" e a decisão é do professor
Aluno usar IA para responder o follow-up	Janela de resposta curta, dentro do ambiente da prova
Pista entregar a resposta	N3 só depois de N2 falhar; nota mediada pondera pelo nível
Pesos arbitrários	Piloto: comparar os perfis gerados com a avaliação do professor sobre os mesmos alunos

Métrica para a demo: concordância entre o perfil gerado e o julgamento do professor, e % de alunos cuja nota real escondia um "Quase lá".

Referências

- Treagust, D. F. (1988). Development and use of diagnostic tests to evaluate students' misconceptions in science. *International Journal of Science Education*, 10, 159–169. Visão geral dos testes de dois níveis
- Tsui, C.-Y. & Treagust, D. (2010). Evaluating secondary students' scientific reasoning in genetics using a two-tier diagnostic instrument. *International Journal of Science Education*, 32(8). Registro · Resenha CBE-LSE
- Poehner, M. E. & Lantolf, J. P. (2013). Bringing the ZPD into the equation: Capturing L2 development during Computerized Dynamic Assessment. *Language Teaching Research*, 17(3). DOI
- Poehner, M. E. (2008). *Dynamic Assessment: A Vygotskian approach*. Springer. Apresentação de Poehner · CALPER, Penn State
- Sotiriadou, P., Logan, D., Daly, A. & Guest, R. (2019). The role of authentic assessment to preserve academic integrity and promote skill development and employability. *Studies in Higher Education*. Griffith · Times Higher Education
- Huxham, M., Campbell, F. & Westwood, J. (2012). Oral versus written assessments: a test of student performance and attitudes. *Assessment & Evaluation in Higher Education*, 37(1), 125–136. Repositório Napier
- Lee, J., Hung, J.-T., Joyner, D. A. et al. (2025). Socratic Mind: Impact of a Novel GenAI-Powered Assessment Tool on Student Learning and Higher-Order Thinking. arXiv · Resumo
- Reboot Foundation. Using AI to Bring Back Oral Exams (inclui o caso NYU). Artigo
- Xu, J. et al. (2025). Exploring the Potential of Conversational AI for Assessing Second Language Oral Proficiency. *TESOL Quarterly*. Wiley
- The AI interviewer: multi-faceted evaluation of adaptive questioning by large language models (2026). *Scientific Reports*. Nature
- Semantic Variability of Replies Across LLMs: Implications for Designing Conversation-Based Assessment (2026). arXiv
- Phan, A. (2023). Impact of Perceived Stress during Oral Examination on Student Performance Outcomes. ASEE. PDF